

Tema 0: Introducción a R y RStudio (Posit)

Pedro Albarrán

Dpto. de Fundamentos del Análisis Económico. Universidad de Alicante



Contenidos I

1 Conceptos básicos

2 Objetos en R

3 Extendiendo R

4 R para análisis de datos

Introducción

- Debéis tener instalados los programas gratuitos R y RStudio
- Nos familiarizaremos con los conceptos y comandos básicos de programación en R
- R es un lenguaje interpretado: ejecuta las instrucciones directamente en la consola
- RStudio es un entorno de desarrollo integrado (IDE) que combina varias herramientas para facilitar el uso de R: consola, **editor** para escribir comandos, ayuda, etc.

R Studio

The screenshot shows the RStudio IDE interface with the following components and highlighted text:

- Source Editor:** Contains an R script file named 'Example.R'. The script defines variables `x` and `y`, combines them into `exanplenat`, and defines a function `afuncion`. A red box over this area says: **Escribir archivos de guión**.
- Environment Panel:** Shows the current environment with objects `exanplenat` (numeric vector) and `afuncion` (function). A red box over this area says: **Información sobre datos, objetos, ...**.
- Console:** Shows the execution of the script commands, including the output of `exanplenat` and the function definition. A red box over this area says: **Consola: ejecución directa de comandos, resultados de guiones**.
- Help Panel:** Displays the documentation for `save` functions. A red box over this area says: **Ver Ayuda, Ficheros, gráficos**.

Empezando con R

- Escribimos *comandos* en la **consola** y se ejecutan pulsando Enter:

- ▶ La tecla de tabulador  ofrece opciones de autocompletado
- ▶ Ejecutar algo que no es un **comando de R** devuelve un error

```
2 + 2  
3 * (1 - 4)^2  
sqrt(log(5/2))  
pi  
hola
```

- O en el **Editor de RStudio** y se envían a la consola la o las líneas seleccionadas para ser evaluadas con el icono  o con el atajo de teclado Ctrl+Enter
- NOTA: en MacOS, usad la tecla Command en lugar de Ctrl

Archivos de guion (“scripts”)

- Es preferible incluir varios comandos en un archivo de texto para ejecutarlos
- Se puede replicar el proceso de cálculos paso a paso (no como Excel)
- Creamos un nuevo archivo con el icono  o en el menú *File > New File > R script* (atajo Ctrl + Mays + N)
- Guardamos el archivo con  o en *File > Save* (atajo Ctrl + S), eligiendo un directorio y nombre de extensión “.R” (por defecto) o “.r”
- En un archivo de guion (guardado), RStudio marca las líneas con error y muestra el mensaje de error al pasar el puntero



Trabajar con ficheros de guion

- Cada comando es “una” línea y se ejecutan secuencialmente
- Un comando se puede extender visualmente más de una línea hasta completarse: p.e., hasta cerrar los paréntesis.
 - ▶ Escribimos `log(`, en otra línea y ejecutamos: la consola cambia de `>` a `+`
 - ▶ No hace “nada” esperando que completemos el comando.
- El carácter `#` marca el inicio de un **comentario**: lo que sigue se “ignora” (no se ejecuta) en R

```
# Pueden ir al principio de la línea  
2 + 2 # o después de una instrucción
```

- Comentar es un buen hábito: ayuda a entender/recordar qué hacemos
- Notad que RStudio tiene *resaltado de sintaxis*: distinto color para comentarios, números, funciones, etc.



Directorio de Trabajo. Proyectos.

- Conviene **organizar los archivos** relacionados con un mismo tema en una estructura de (sub)directorios a partir de un **directorio de trabajo** principal
- RStudio permite definir **proyectos** para gestionarlo fácilmente a través del menú *File* o desplegando el icono en la parte superior derecha  Project: (None) ▾
- Desde el menú *File > New Project* o desde el icono, creamos un nuevo proyecto:
 - ▶ Podemos usar un *Nuevo Directorio* o elegir una ubicación ya existente
 - ▶ El **nombre del proyecto será el nombre del directorio**
 - ▶ También se crea un archivo con el mismo nombre y extensión “.Rproj”
- Al abrir RStudio, tenemos activo el último proyecto abierto: ej.,  Tema00 ▾
- Tanto desde el menú como desde el icono de gestión de proyectos, podemos
 - ▶ cerrar el proyecto actual, *File > Close Projects*,
 - ▶ abrir otros proyectos guardados: *File > Open Project* o *File > Recent Projects* 

Proyectos (cont.)

- Para trabajar con un archivo, usamos la **ruta relativa** al directorio de trabajo:
 - ▶ si están en el raíz del directorio: `codigo.R`, `misdatos.Rdata`
 - ▶ si están en un subdirectorio, indicamos la ruta separando directorios por `/`:
`datos/ventas.Rdata`, `datos/ano2020/ingresos.Rdata`
- La **pestaña**  en el cuadrante inferior-derecho ofrece una forma visual de abrir, crear, copiar, mover o eliminar archivos o directorios, etc.
- Evitad caracteres “raros” (acentos, espacios, etc.) en directorios y ficheros
- NOTA. El Explorador de Archivos de Windows y Finder de MacOS, no muestran defecto las extensiones de los archivos.
 - ▶ Puede ser confuso para distinguir entre dos archivos con el mismo nombre y diferente extensión: `proyecto.R` y `proyecto.Rproj`
 - ▶ Consultad cómo mostrarlas: p.e., para Windows y MacOS



Funciones en R

- Las expresiones que aceptan **argumentos** se denominan funciones.

```
exp(2)
ceiling(5.2)
```

- Algunos argumentos son obligatorios, otros tienen valores por defecto que se pueden omitir
- Los argumentos se pueden especificar por nombre o por orden.

```
log(2, base=2)
log(2, 10)
log(base = 10, x = 2)
```

- ¿Cómo sabemos la manera de usar una función (ej. argumentos necesarios) o comando de R?

Ayuda en R y RStudio

- RStudio tiene autocompletado y ayuda flotante para funciones y otros elementos de R
 - ▶ P.e., si empezamos a escribir la función `log`, se muestra la forma esperada de trabajar con esa función
- RStudio también tiene una **pestaña** para buscar ayuda
- Las búsquedas online o las IAs (como chatGPT, Gemini o Copilot) pueden ser útiles.
- PERO debemos tener un conocimiento mínimo para aprovechar realmente una solución
 - ▶ hay muchas formas de hacer lo mismo en R: una respuesta correcta puede no ajustarse a lo que ya sabemos
- NO uséis copiar-pegar **sin entender** el código: copiar-pensar-adaptar



El operador de asignación

- El operador `<-` almacena un contenido en un *objeto* con un nombre,¹ que incluye letras, números y algunos caracteres especiales (“”, “_”)

```
x <- 2*3      # asignación, no muestra resultado
x             # ejecutamos mostrar la variable
print(x)
(x <- 2)      # asignación e impresión a la vez
```

- R es “case-sensitive”: `x` y `X` son dos objetos distintos
- Los objetos asignados pueden usarse posteriormente, p.e., para generar otros a partir de ellos

```
y <- x + 5    # asignamos y a partir del VALOR de x
(x <- x*3)    # re-asignamos x a partir de ella misma
y            # NO cambia (en Excel, sí)
```

¹También se puede asignar con `=`

El Espacio de Trabajo en R

- El espacio de trabajo es el conjunto de objetos activos en memoria, resultado de todos los comandos ejecutados previamente
- En RStudio, la pestaña **Environment** muestra los objetos y su valor
- Las funciones `ls()` y `rm()` muestran y eliminan respectivamente objetos del espacio de trabajo
- Borraremos *todos* los objetos con  en el **Environment** o el comando

```
rm( list=ls() ) # eliminar todos los objetos
rm(y, x)       # eliminar solo algunos objetos
```

- Guardamos el contenido del entorno de trabajo con  (o al cerrar RStudio), pero es **innecesario**: ejecutando los comandos guardados en un archivo `.R` recuperamos los objetos

Mensajes de “Error” y “Warning”

- En programación, cometer **errores** es **normal**
- En muchos errores, R se “quejará” mostrando **mensajes** en rojo
 - ▶ *Aviso*: R ofrece un resultado (y continuará al siguiente comando), PERO indica que puede haber algo “no deseado”
 - ▶ *Error*: para la ejecución, *sin resultado*, e “informa” de la razón
- Algunos mensajes son claros, pero otros requieren más investigación
- Peor que un mensaje de error: escribimos (copiamos) un código que funciona pero no hace lo que queremos...
- El ordenador NO se equivoca: hace lo que le pedimos según unas reglas bien definidas por R, que *debemos conocer*
 - ▶ Sed cuidadosos, pensad y **entended** cada paso del código

Tipos de Objetos en R

- TODO en R es un objeto, cada uno con **distintas propiedades** y, por tanto, distintas formas de trabajar con él
- Además de las funciones, los principales objetos con los que trabajaremos son:
 - 1 vectores
 - 2 factores
 - 3 conjuntos de datos (“data frames”)
 - 4 listas
- Estos objetos pueden contener varios tipos de datos o variables:
 - ▶ entero
 - ▶ numérico (números reales)
 - ▶ lógico (valores verdadero/falso)
 - ▶ caracteres

Vectores

- Un vector es una secuencia de datos elementales, creados con el operador “c()” (combinar)

```
x <- c(2.5, -4.1, 6.4, 8.2)      # vector numérico
y <- c(3, 0, -1, 2)             # vector de enteros
w <- c("hola", 'adios')         # vector de caracteres
z <- c(FALSE, TRUE, T, F)       # vector lógico
```

- Podemos crear vectores a partir de otros vectores o usando comandos

```
z <- c(x, y)
x <- rep(1, times=4)
y <- seq(from = 10, to = 1, by = -1)
z <- 1:10      # equivale a z <- seq(1,10,1)
```

- Un vector sólo puede contener objetos de un **único tipo** elemental, que podemos conocer en el Environment o con str()

Vectores (cont.)

- Si se mezclan tipos distintos, R busca una clase que “acomode” a todos

```
vcr <- c("lunes", 2)
```

- Forzamos que un objeto sea tratado con una clase concreta, con `as.integer()`, `as.numeric()`, `as.character()` y `as.logical()`
 - ▶ Si no se puede convertir a número, devuelve NA (con un “warning”)
- NO se pueden realizar operaciones incompatibles entre clases
 - ▶ Cuidado con las comillas: NO es lo mismo un objeto (su contenido) que el carácter de su nombre

```
a <- 4  
c <- 'a' + 1
```

- Los vectores pueden tener *nombres* (una “etiqueta” única para cada elemento): un vector de caracteres de la misma longitud asignado con `names()`

Aritmética de vectores

- La mayoría de los operadores se aplican *elemento-a-elemento*

```
a <- seq(1,3,1)
b <- seq(6,8,1)
```

```
a+b
a*b
```

- Con diferentes longitudes, se repite el vector corto cuanto sea necesario

```
b <- 6:9
a + b
a + 1 # lo que queremos!
```

- Algunas **funciones** relevantes

```
length(x) # longitud
sort(x)   # ordenar
max(x)    # máximo
min(x)    # mínimos
sum(x)    # suma
prod(x)   # producto
```

```
mean(x)    # media
var(x)     # varianza
table(x)   # frecuencias
summary(x) # estadísticos
```



Vectores lógicos

- Obtenemos un objeto lógico enunciando una relación que puede ser cierta o falsa , como comparaciones básicas de igualdad o desigualdad

```
1 == 1 # TRUE
1 != 3 # TRUE
1 > 2  # FALSE
```

```
a <- 3
a >= 3 # TRUE
a + 1 <= 10 # FALSE
```

- Combinamos varios enunciados con operadores Y (&), O (|) y NO (!)
- Para conjuntos, `x %in% Y` es cierto cuando `x` es un elemento de `Y`

```
altura <- c(176, 165, 189, 155, 168)
```

```
altura >= c(175, 165, 195, 165, 168) # elemento a elemento
altura == 155                         # elemento a elemento
```

```
altura > 160 & altura <= 180
```

```
altura < 160 | altura >= 180
```

```
c(165,179) %in% altura
```

```
condicion <- !(altura <= 170)
```



Acceso a los elementos de un vector

- Se utiliza el operador `[]` (paréntesis cuadrado)² y

❶ **Posiciones** de los elementos, usando un vector de enteros

```
altura[3]  
altura[c(1,3,5)]
```

- Con enteros negativos, indicamos posiciones que NO queremos

```
altura[-c(2,4)]
```

❷ **Condición** que satisfacen los elementos, usando un vector lógico

```
altura[altura > 180 | altura < 160]
```

❸ (Si lo tienen) **Nombres** de los elementos, usando un vector de caracteres

²También con `[[]]`

Factores

- La **información cualitativa** se suele codificar como texto o números, pero NO tiene sentido numérico (ni de “texto”): *representan* clases o **categorías**
- Para destacar la naturaleza distinta de estos datos, existe un tipo de objeto específico en R: los **factores**
- Además de otras ventajas que veremos, permiten separar la representación original de las categorías (niveles) de cómo queremos mostrarlas (etiquetas)

```
genero    <- c(2, 1, 2, 2, 2)
genero_f  <- factor(genero, levels = c(1, 2),
                    labels = c("Mujer", "Hombre"))
```

- Se asocia nivel 1 con “Mujer”, 2 con “Hombre”, etc.
- Las operaciones con factores se realiza con las etiquetas, no con los niveles

```
genero_f == 1      # NO existe valor 1
genero_f == "Mujer"
```



Factores (cont.)

- También podemos usar `as.factor()` para convertir un vector en un factor
- PERO es conveniente especificar los niveles y las categorías porque si no, R los asigna alfabéticamente

```
g <- factor(genero) # as.factor(genero) hace lo mismo
g
```

- En este caso la etiqueta del primer nivel encontrado en los datos (el número 2) es "1" y la del siguiente nivel (el número 1) es "2"
- También podemos tener factores con orden con la opción `order = TRUE` y enumerando los niveles en orden

```
satisf <- c("A", "B", "A", "B", "M")
satisf_f <- factor(satisf, order = TRUE,
                  levels = c("B", "M", "A"),
                  labels = c("Bajo", "Medio", "Alto"))
```

“Resumiendo” un vector numérico o un factor

- La función `summary()` devuelve los principales estadísticos descriptivos de un vector numérico

```
summary(altura)
```

- Para información cualitativa, la media y otros estadísticos no tienen sentido

```
summary(genero)
genero <- c(1, 20, 20, 1, 1) # dos categorías igualmente
summary(genero)
```

- La función `summary()` ofrece resultados diferentes según el tipo de objeto (porque tiene distintas propiedades)

```
summary(genero_f)
```

“Data Frames”

- Es un tipo de objetos específico para facilitar el análisis de datos: una colección de variables por columnas y observaciones por filas.
- Cada columna es un vector con un **nombre** y tipos de datos (quizás) diferentes

```
altura <- c(177, 178, 168, 164, 186, 162, 160)
peso   <- c(75, 85, 70, 60, 80, 65, 54)
genero <- c(2, 1, 2, 2, 2, 1, 1)
genero_f <- factor(genero, levels = c(1, 2),
                  labels = c("Mujer", "Hombre"))
datos <- data.frame("Altura"=altura, "Peso"=peso, "Genero"= genero_f)
```

- Se visualizan con View(datos) o en “Environment” o una parte con head()
- Seleccionamos columnas por nombre con \$ o por nombre o posición con [[]]

```
vectAltura <- datos$Altura # objeto resultante = vector
datos[[2]] == datos[["Peso"]]
```



“Data Frames” (cont.)

- También podemos usar `[]` para seleccionar filas y columnas por posición, nombre y/o condición lógica

```
datos1 <- datos[datos$Genero == "Hombre", 1:2] # Altura y Peso de hombres
```

- Suele ser mejor usar `subset()` que devuelve siempre un “data frame”

```
D1 <- subset(datos, Altura > 165)
D2 <- subset(datos, subset = Altura %in% c(177,178),
              select = c(Altura, Peso))
```

- Generamos nuevas variables con el vector de asignación

```
datos$Altura_m <- datos$Altura / 100
```

- Se pueden añadir filas y columnas a un *data frame* con `rbind()` y `cbind()`, respectivamente, a partir de vectores u otros *data frames*

Listas

- Una lista es una colección de objetos de distinto tipo (a diferencia de un vector)
- Los elementos de una lista suelen tener nombres

```
miLista <- list(saludo="hola", vec=x, lista=list(1:4, "X"),
               datos=datos)
```

- Con `[[]]` (por posición o por nombre) o con `$` (solo por nombre) extraemos los elementos en su clase original

```
miLista$vec
miLista[[2]] + 3
```

- También podemos usar `[]`, pero devuelve una lista
- `unlist()` convierte una lista en vector, usando la clase que pueda ajustarse a todos los objetos (elementales)



Bibliotecas (“libraries”)

- Una biblioteca contiene nuevos objetos de R: funciones, datos, etc.
- Para instalar una nueva biblioteca (se hace **una vez**), en *Tools* > *Install packages* o en **Packages** o con el comando

```
install.packages("AER")
```

- Mantenemos actualizados los paquetes, en el menú *Tools* o en **Packages**
- La biblioteca solo está disponible si se carga en la *sesión actual*

```
library(AER)
```

- Nota: en adelante, la bibliotecas que carguemos se suponen instaladas
- En **Packages** vemos las bibliotecas instaladas y las cargadas aparecen marcadas

System Library

☒ base☐ boot

Bibliotecas (cont.)

- El nombre completo de un objeto es `biblioteca::nombre`
 - ▶ La nombre de la biblioteca solo es necesaria si no se ha cargado o dos objetos diferentes tienen el mismo nombre en bibliotecas distintas

```
base::log(1)
log(1)
```

```
library(Hmisc)
find("units")
```

- Para mostrar todos los datos de las bibliotecas cargadas

```
data()
```


- Los podemos cargar en el “Environment” y obtener información detallada en la ayuda (ej., nombre de variables)

```
data("Affairs")
help("Affairs")
```

Datos “nativos” en R

- Guardamos objetos del espacio de trabajo con `save()` (en una ruta relativa al directorio de trabajo)

```
x <- 1:20
y <- 2 * x ^ 2 + 1
save(x, file="x.RData")          # un objeto, o varios
save(x, y, file="data/xy.RData") # separados por comas
```

- Para cargar datos al espacio de trabajo, con `load()` (= icono )

```
load("data/xy.RData")
```

- En la pestaña de **Files**: doble-clic carga un archivo de datos
- Nota: este tipo de archivo puede contener varios objetos, incluidas varios conjuntos de datos

Datos en otros formatos externos a R

- Varias bibliotecas permiten trabajar con distintos formatos de datos, p.e.:
 - 1 Texto, con delimitadores o de ancho fijo: `utils` (R base), `readr`
 - 2 Hojas de cálculo: `readxl`, `openxlsx`
 - 3 Formatos de software estadístico: `haven`, `foreign`
- Descargad estos ejemplos (UA cloud): `renta.txt`, `sex_data.csv`, `beauty.xls`, `nsw.dta`
- En  de RStudio, tenemos acceso visual para cargar algunos formatos (con la biblioteca necesaria instalada)
- `rio` es un meta-paquete (instala otras bibliotecas) para importar y exportar varios formatos de datos de forma sencilla
 - ▶ A partir de la extensión del archivo, detecta el formato y, por tanto, la biblioteca necesaria

Importar y exportar con rio

- rio permite trabajar con el **mismo comando** para todos los formatos, pero las opciones por defecto pueden no ser adecuadas
 - ▶ En la Ayuda se incluye una presentación completa del paquete
- El comando `import()` se usa para leer los datos

```
library(rio)
sex    <- import("data/sex_data.csv")
renta  <- import("data/renta.txt")
beauty <- import("data/beauty.xls")
nsw    <- import("data/nsw.dta")      # formato Stata
```

- Podemos exportar datos a un tipo de formato con `export()`

```
export(nsw, "data/nsw.csv")
```

- O convertir un archivo del disco a otro formato con `convert()`

Otras fuentes de datos

- Bibliotecas con datos muy utilizados: `pwt` (“Penn World Tables”)
- Bibliotecas con funciones para obtener datos online (con APIs públicas)
 - ▶ datos de las OECD y eurostat (incluye datos del INE español)
 - ▶ `rdbnomics` para los datos gratuitos de <https://db.nomics.world/>
 - ▶ datos económicos y financieros con `quantmod` y `tidyquant`
 - ▶ `quandl` (de pago)
- `qualtRics` trabaja con software de encuestas `qualtrics`
- Descarga de páginas web y *webscraping* con las bibliotecas `rvest` y `httr` (función `GET()`)
- `googlesheets4`
- DBI accede con Bases de Datos relaciones (SQL)



Gráficos Básicos

- Podemos representar gráficos de dos variables o funciones

```
x <- c(3, 4, 5, 6, 7, 8)
y <- c(5, 3, 7, 7, 5, 10)
```

```
plot(x,y)
```

- El resultado aparece en la pestaña *Plots* de RStudio
- Podemos cambiar opciones (ver Ayuda de `plot.default`) como *type* (puntos, líneas, etc.), símbolo de punto (*pch*), tipo de línea (*lty*), ancho de línea (*lwd*), color (*col*), título, etiquetas de los ejes, etc.

```
plot(x, y, type="b", pch=3)
plot(x, y, type="l", lty=2, lwd=2)
plot(x, y, xlab="Eje X", ylab="Eje Y", main="Mi título")
```

- Se pueden cambiar más opciones con `par()`, combinar gráficos, añadir líneas, texto, etc. y exportar los gráficos

Estadísticos descriptivos: variables discretas

- Para variables discretas (factores), `table()` calcula distribuciones de frecuencias de una variable o conjuntas: el resultado es un **objeto**

```
data("PSID1982", package = "AER")  
(frec <- table(PSID1982$occupation) )  
(frec2 <- table(PSID1982$occupation, PSID1982$ethnicity))
```

- Podemos mostrar frecuencias relativas con `prop.table()`

```
prop.table(frec)  
prop.table(frec2)
```

```
prop.table(frec2, margin = 1)  
prop.table(frec2, margin = 2)
```

- También es informativa su representación con gráficos de barras

```
barplot(frec, horiz = T)
```

```
barplot(prop.table(frec2), beside = T)
```

Estadísticos descriptivos: variables continuas

```
data(ceosal1, package='wooldridge')
```

- Ya hemos visto funciones de estadísticos como `mean()`, `var()`, etc.

```
median(ceosal1$salary)
var(ceosal1$salary)
```

```
quantile(ceosal1$salary,
         probs=c(0.25, 0.75) ) # 1er y 3er cuartil
```

```
summary(ceosal1$salary) # de una variable (vector)
summary(ceosal1)       # de todo el conjunto de datos
```

```
cov(ceosal1$salary, ceosal1$roe) # covarianza
cor(ceosal1$salary, ceosal1$roe) # correlación
```

Estadísticos descriptivos: variables continuas (cont.)

- Para variables continuas, las frecuencias de valores en un *intervalo* se pueden tabular o graficar en un histograma

```
hist(ceosal1$roe)    # intervalos automáticos
```

```
hist(ceosal1$roe, freq=F,          # densidad, no casos  
     breaks=c(0,5,10,20,30,60)) # intervalos explícitos
```

- O la densidad (versión suavizada del histograma)

```
plot(density(ceosal1$roe))
```

- Un gráfico de caja ofrece información resumida de la distribución: mediana, 1er y 3er cuartil, y valores “extremos”

```
boxplot(ceosal1$roe, horizontal=T)
```

```
boxplot(ceosal1$roe~ceosal1$consprod)
```

Valores ausentes (“missing values”): NA

- Muchos conjuntos de datos tienen valores ausentes de ciertas observaciones para algunas variables: ej., descargad (UA Cloud) `earn.RData`
- Sabemos si una observación es NA y la frecuencia total:

```
load("data/earn.RData")  
x <- earn$earnings
```

```
is.na(x)  
table(is.na(x))
```

- Por defecto en R, un cálculo con NAs es NA: debemos decir que los elimine explícitamente (y ser conscientes de lo que implica)

```
mean(x)
```

```
mean(x, na.rm=TRUE)
```

- `na.omit()` elimina observaciones con NAs de una o varias variables

```
earn2 <- na.omit(earn)
```

- ¿Cómo tratar los NAs? Eliminarlos implica selección muestral y la alternativa de imputar valores implica supuestos sobre éstos



Nota sobre programación “avanzada”

- Como en todo lenguaje de programación R, tiene funciones para
 - ▶ Ejecución condicional `if()`: una parte del código se ejecuta solo si se cumple una condición
 - ▶ Bucles `for()`: se repite un mismo bloque de código mientras se itera por los valores de vector
 - ▶ Crear funciones propias con `function()`
- Una variante de la ejecución condicional, solo para crear variables según una condición

```
data("Affairs", package = "AER")  
Affairs$univers <- ifelse(Affairs$education>15, 1, 0)
```